Conexión al proxy LiteLLM de ITBA

Este ejemplo muestra cómo conectarse al proxy de ITBA con el SDK de OpenAI y enviar una primera consulta. LiteLLM expone una API compatible con OpenAI, por lo que solo necesitamos indicar la URL del proxy y nuestra API key.

¿Qué es LiteLLM?

LiteLLM es un proxy de código abierto que actúa como capa de abstracción entre tu código y múltiples proveedores de LLMs (OpenAI, Anthropic, Google, etc.). En lugar de conectarte directamente a cada proveedor con sus propias APIs y formatos, tu código siempre habla con LiteLLM usando el formato estándar de OpenAI.

Esto significa que:

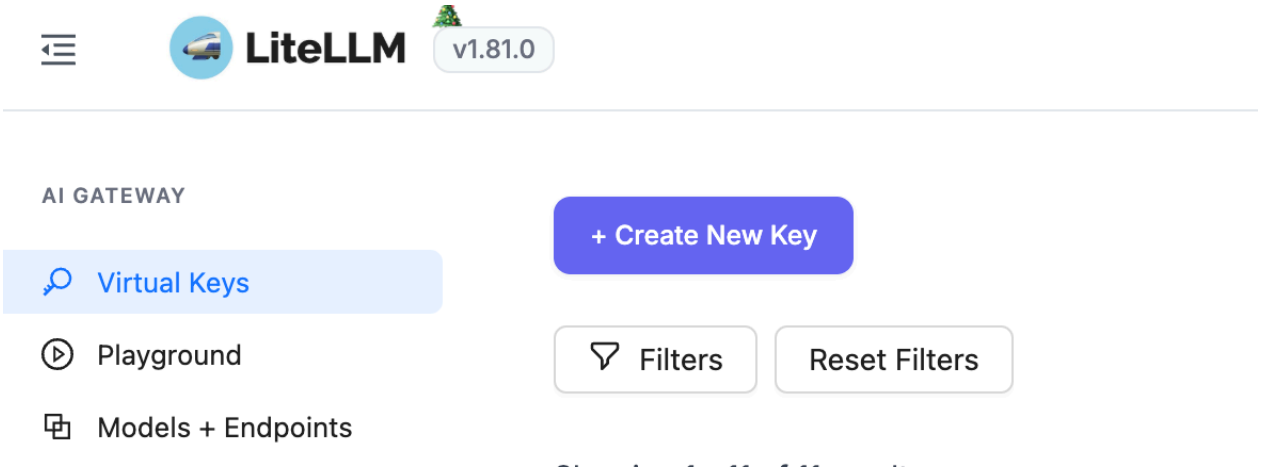
- **Un solo SDK** (`openai`) funciona con todos los modelos configurados en el proxy.
- Las **credenciales reales** de los proveedores quedan en el servidor del proxy, nunca en tu código.
- Puedes **cambiar de modelo** en una sola línea sin reescribir la lógica de tu aplicación.

Durante este curso, todas las llamadas a modelos pasarán por el proxy LiteLLM que ya está configurado para cada equipo.

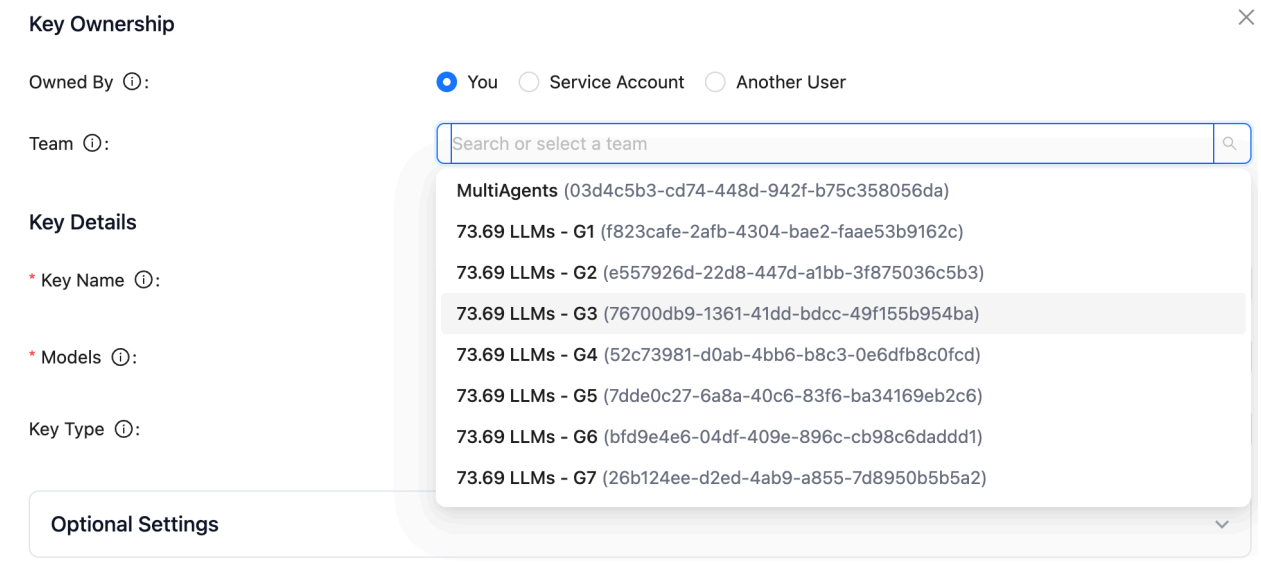
Para más información sobre uso revisar la documentación: https://docs.litellm.ai/docs/proxy/docker_quick_start

Antes de comenzar

1. Cada estudiante recibirá una invitación por mail para crear su usuario en LiteLLM
2. Se deberá crear una virtual key por grupo (de más está aclarar que el uso estará monitoreado por los administradores del ambiente y no se permitirá el uso personal de las API Keys)

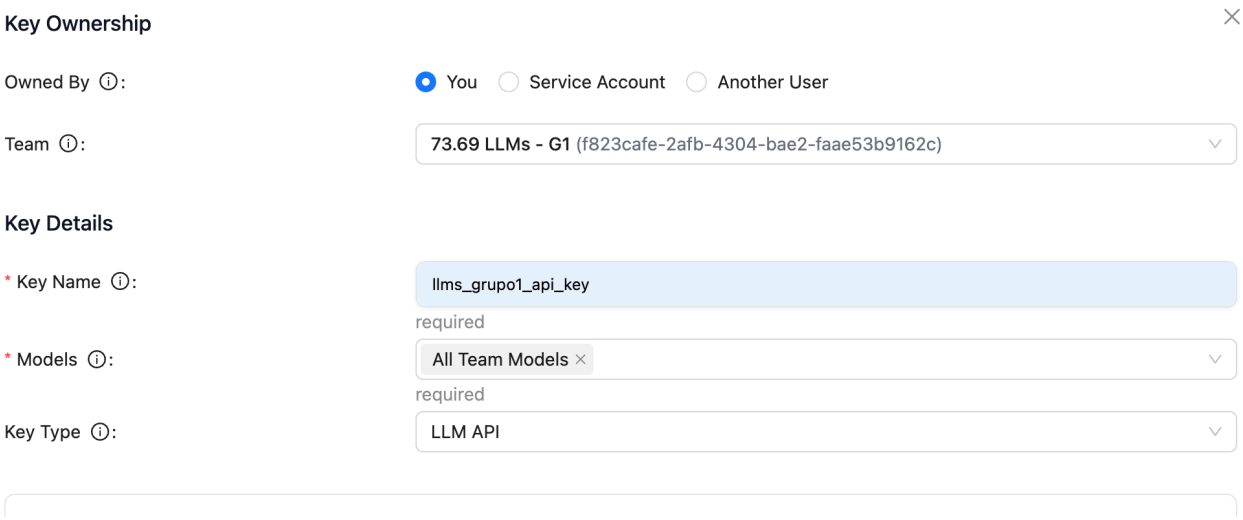


3. Cada uno deberá seleccionar el grupo correspondiente al que pertenecerá la API Key



!

4. La configuración de cada API Key es la siguiente:



5. Guardar la key en un archivo .env

IMPORTANTE: Dado que el ambiente es compartido con otras materias, les pedimos que presten especial atención al seleccionar el grupo correspondiente y que monitoreen el uso de las API Keys.

Recuerden comenzar utilizando modelos más simples y escalar a modelos de mayor complejidad únicamente cuando sea necesario, teniendo siempre en cuenta el consumo de tokens y el uso responsable de los recursos disponibles.

```
%pip install -q openai python-dotenv
```

Primera consulta

Pueden encontrar ejemplos sencillos para conectarse en https://sa-llmproxy.it.itba.edu.ar/ui/?login=success&page=api_ref, especialmente el de OpenAI y Langchain (LlamaIndex no lo utilizaremos en la materia) Crea un archivo `.env` junto al notebook con el siguiente contenido:

```
LLM_API_KEY=tu_virtual_api_key
```

El archivo `.env` está excluido de Git, por lo que la clave no se comparte al publicar el repositorio. En Google Colab, sube `.env` a la sesión antes de ejecutar la celda siguiente.

```
import os
import openai
from dotenv import load_dotenv

load_dotenv()
api_key = os.getenv("LLM_API_KEY")

if not api_key:
    raise RuntimeError("No se encontró LLM_API_KEY en el archivo .env")

client = openai.OpenAI(
    api_key=api_key,
    base_url="https://sa-llmproxy.it.itba.edu.ar/",
)

response = client.chat.completions.create(
    model="gpt-3.5-turbo",
    messages=[
        {
            "role": "user",
            "content": "This is a test request. Write a short poem.",
        }
    ],
)

print(response.choices[0].message.content)
```

```
In the quiet garden of my mind,
Where thoughts and dreams intertwine,
I find solace in the gentle breeze,
And the whispers of the trees.
```

```
In this sanctuary of my own,
I am free to roam and to be alone,
To ponder the mysteries of life,
And embrace both joy and strife.

The beauty of this inner place,
Fills me with a sense of grace,
A refuge from the world outside,
Where I can truly be myself, unapplied.
```